

2025 年第五届“点宽杯”全国高校 金融科技黑客松大赛

题目 : 量化投资方向因子选股策略构建

队伍 ID : 852

论文名称 : 基于 LightGBM 的沪深 300 多因子选股
策略研究

摘要

本研究基于沪深 300 成分股日频数据，构建了一套“市场状态识别+机器学习多因子选股”的双层量化选股策略体系。首先，在风险控制层面，本文利用成分股等权价格序列构造伪指数，并通过 60 日与 120 日均线及 20 日动量对市场强弱状态进行识别，形成 0.45 - 1.00 区间的动态仓位调整参数，从而在弱势行情中主动收缩仓位、控制下行风险。在选股层面，本文以价量信息为基础构建了包含动量、反转、波动率与流动性在内的七个多因子指标，并采用滚动面板方式训练 LightGBM 回归模型，以预测个股未来 20 日收益率。在样本质量不足或模型稳定性较弱时，策略自动退回基于 60 日动量的线性排序逻辑，以确保整体决策的稳健性。调仓周期设为 5 个交易日，每期选取预测得分最高的 25 只股票进行等权配置。

在 2022 年 9 月至 2025 年 9 月的样本区间内，策略实现**累计收益 81.87%**，**年化收益率为 23.04%**，显著优于同期沪深 300 指数的 11.87%，**信息比率达到 1.07**，**最大回撤控制在 20.40%**，**夏普比率为 0.89**，显示出良好的风险收益水平。结果表明，机器学习与传统因子框架结合、并辅以市场状态识别进行仓位调节，可有效提升选股策略的稳定性与抗风险能力。本文进一步从因子贡献、模型有效性及风险暴露角度进行了分析，为多因子模型在国内指数增强策略中的应用提供了实践参考。

关键词：多因子模型；机器学习；LightGBM；市场状态识别；沪深 300；量化选股

一、引言与研究背景

近年来，A 股市场的主动管理与 Smart Beta 策略面临着从“因子挖掘”到“预测范式”的范式转移压力。传统线性多因子模型（如 Fama-French 三因子模型）在解释横截面收益时，对因子间的非线性关系与复杂交互项刻画不足，且在市场风格快速切换时适应性差，回撤控制能力弱，此即所谓的“能打但易爆”困境。

随着数据可得性与计算能力的大幅提升，主动权益管理与智能贝塔（Smart Beta）策略在国内外均得到了广泛关注。传统基于市值加权的被动投资在降低成本和复制市场方面表现优异，但在追求稳定超额收益与风险控制时，主动管理与因子增强策略仍被认为具有重要价值。经典多因子框架（如 Fama - French 三因子/五因子模型）为解释横截面收益提供了坚实理论基础，并为因子选股与风险分解提供了规范化工具。

传统线性多因子方法在实践中仍面临两类主要挑战。其一，许多因子之间存在显著的非线性关系与交互效应，线性回归框架难以完整刻画这些复杂结构，从而可能低估或错估因子贡献。其二，在市场风格快速切换或极端行情下，基于固定线性权重的因子组合容易失灵，难以实现稳健的下行风险控制。针对上述问题，近年来学术界与业界开始引入更灵活的机器学习方法，以挖掘因子间的非线性关系并提高预测精度。Gu、Kelly 与 Xiu (2020) 等研究表明，树模型与神经网络在资产定价与收益预测任务中能够显著提升经济收益，且其优势部分来源于对非线性与交互项的捕捉能力。

在因子研究领域另一重要议题是“因子挖掘与多重检验”问题（即所谓的 factor-zoo），大量可用特征和统计检验导致显著性判定的偏误与过拟合风险，需要在模型设计中注重稳健性检验与多重比较调整。Harvey 等人对此类问题的讨论提醒我们，在构建因子和评估模型效果时应慎重处理样本外验证与统计显著性问题。

基于上述背景，本文在沪深 300 成分股范围内提出并实现了一套两层策略架构：上层为“市场状态识别”与动态仓位调节，下层为基于价量信息的 LightGBM 多因子选股模型。该设计旨在同时解决（1）模型对因子间非线性与交互项的刻画不足问题，以及（2）在风格切换或弱势市场中对整体仓位的主动收缩需求，从而在保证稳健性的前提下获取超额收益。为验证方法有效性，本文在 2022 - 2025 样本期内对所提策略进行了回测与一系列鲁棒性检验，结果显示在控制最大回撤的情况下，结合机器学习的多因子框架能够显著提高信息比率与累计超额收益（参见第 8 章）。同时，本文在模型实现层面设计了样本质量检测与基线兜底逻辑（当模型不稳时退回 60 日动量排序），以减少机器学习方法可能带来的过拟合与运行风险。

本文的贡献在于：一方面将机器学习方法（LightGBM）系统化地引入到成分股级别的截面选股中，验证其对中短期收益预测的改进效果；另一方面融合简单透明的市场状态识别机制，实现动态仓位管理，从工程与实务角度提升策略的鲁棒性与可操作性。接下来的章节将依次介绍数据与平台环境、因子设计、模型构建、交易规则、回测设置与实证结果，并对策略的稳定性与改进方向进行讨论。

二、数据说明与平台环境

本研究使用的数据来自 AT-edu 金融科技教学与研究平台所提供的沪深 300 成分股日频行情数据。AT-edu 平台由量化研究工具 ATRader (atrader) 提供底层支持，数据源涵盖沪深两市上市公司成分股的日交易数据，包括收盘价（close）、成交量（volume）、最高价、最低价、涨跌幅等基础行情字段，同时提供指数层面的行情序列。由于本研究聚焦于多因子选股与市场状态识别，所用因子均基于日收盘价与成交量构建，因此平台提供的标准化行情字段即可满足研究需求，避免了额外的数据预处理偏差。

本研究所采用的主回测区间为年 9 月 1 日至 2025 年 9 月 1 日。其中，模型有效评估

区间主要集中在 2022 年至 2025 年，这一时期 A 股市场波动显著、风格切换频繁，有利于检验机器学习多因子策略在不同市场环境下的表现。此外，部分扩展实验（如参数敏感性和鲁棒性检验）在更长区间上进行，并在后文附录中说明。整个研究严格使用平台提供的原始日频行情，未使用任何外部私有数据，以保证研究方法的可复现性和公平性。

策略开发与回测均基于 AT-edu 平台的标准 Python 策略框架完成。该框架包含数据注册（`reg_kdata`）、历史窗口提取（`get_reg_kdata`）、账户管理（`context.account`）、下单指令（`order_target_volume`）等核心 API，能够模拟实际交易环境的订单执行方式、滑点机制与资金变化过程。本研究的全部策略逻辑均封装在同一个 Python 脚本文件中，包括因子计算、样本构造、LightGBM 模型训练、兜底机制、仓位控制以及调仓执行等模块。由于 ATRader 支持在本地环境运行同样的策略文件，本研究实现了“本地开发—平台回测—比赛评测”全流程环境一致，最大程度减少了策略迁移误差与工程偏差。

此外，AT-edu 平台对沪深 300 成分股进行统一标的管理，在回测过程中通过 `target_list` 直接调用成分股列表，从而保证了样本内外一致性，避免了手动管理成分股可能带来的前视偏差（look-ahead bias）。策略运行过程中，数据按交易日顺序逐步推送至 `on_data` 回调函数，使得因子计算、模型训练和调仓决策均严格基于当时可得信息，确保不存在未来函数问题。总体而言，本研究所基于的平台环境在数据质量、运行机制及策略执行逻辑上均具备较高一致性，为模型的可复现性与结果可靠性提供了保证。

三、策略总体框架

本研究构建的策略体系采用典型的“两层结构”设计：上层负责识别市场状态并调整组合总体仓位，下层基于多因子与机器学习模型进行个股收益预测与选股决策。该架构兼顾了传统多因子模型的解释性与机器学习模型的非线性拟合能力，同时通过动态仓位管理缓解了市场风格切换带来的系统性风险，在工程上具有可解释性、可控性与较强的鲁棒性。本节将对策略的整体结构、运行流程以及各部分之间的关系进行详细描述。

（一）双层架构设计思路

策略整体逻辑由“市场状态识别层（上层）”与“机器学习多因子选股层（下层）”两部分组成，其核心逻辑如下：

1. 市场状态识别层（Regime Layer）

通过成分股构造等权指数，并计算 60 日与 120 日均线及近 20 日动量，以识别市场所处的强势、弱势或震荡状态。根据市场强弱程度，策略动态调整总体仓位系数 `risk_mult` $\in [0.45, 1.00]$ ：

- （1）强势行情（价格高于 MA60）：满仓 100%
- （2）中性行情（MA60 下/ MA120 上）：保持 85% 仓位
- （3）弱势行情（跌破 MA120）：降低至 65%
- （4）弱势叠加负动量：进一步降至 45%

这一机制的作用类似于动态风险预算，让组合在上涨期保持进攻性，在下跌期主动收缩敞口，从而显著降低结构性回撤。

2. 机器学习多因子选股层（ML-Factor Layer）

在给定的可投资股票池（沪深 300 成分股）中，策略构建基于价量特征的七因子体系，并采用滚动面板（rolling panel）的方式训练 LightGBM 回归模型，用以预测个股未来 20 日收益。模型预测结果与传统动量因子按权重融合，然后进行收益排序，选取排名前 25 个股票构建等权组合。

为保证模型在样本不足或训练不稳定情况下仍能运行，策略设计了“兜底机制”：若检测到模型预测退化、训练样本少于设定阈值、特征异常或训练失败，则自动切换为简单

且稳健的“60 日动量排序”逻辑。

两层结构在策略内部通过数据流与仓位指令联动：市场状态决定组合总体仓位，而个股排序决定资金在股票之间的分配比例，共同构成交易日内的最终调仓决策。

（二）策略运行流程

策略执行完全基于 AT-edu 平台的数据推送机制，每个交易日由平台触发 `on_data` 函数，完成以下步骤：

1.数据更新与窗口构造

策略首先调用平台提供的 `get_reg_kdata` API，更新沪深 300 成分股的历史收盘价与成交量序列，并以此构建因子窗口（121 日）与预测标签窗口（未来 20 日）。

2.是否触发调仓判断

策略采用固定 5 日调仓周期，仅在满足周期条件时才执行训练与调仓，以降低交易成本与模型计算量。

3.上层：市场状态识别与总体仓位确定

依据最近 120 日指数均价序列，计算 `pseudo-index` 的 `MA60`、`MA120` 与 20 日动量，确定 `risk_mult`。该值随后作为组合的目标资金配置比例，用于控制本期可动用资金规模。

4.下层：LightGBM 训练与个股得分计算

策略使用滚动面板数据构建训练集与当日预测特征 `X_today`，训练 `LightGBM` 回归模型，输出每只股票的未来 20 日收益预测值。模型预测得分与动量得分按固定权重组合，形成最终评分。

5.股票池排序与选股

按评分从高到低排序，选出前 `TOP_N = 25` 只股票构建组合，权重均分。

6.目标持仓计算与下单执行

按总体仓位 `risk_mult` 计算目标持仓规模，并通过 `order_target_volume` API 完成买卖指令。平台自动模拟撮合、滑点、资金变化并输出每日资产序列与交易记录。

该流程确保策略在数据获取、因子计算、模型训练、调仓决策与订单执行间运作流畅且可复现，严格遵循“只有当日信息可用”的原则，避免出现未来函数。

（三）策略框架示意图



四、因子设计与经济含义

本研究采用 7 个基于价格与成交量构建的基础因子，用于刻画个股在趋势、均值回复、风险暴露与流动性方面的特征。这些因子均可由日频行情数据计算得到，结构简单、可解释性强，并适合在滚动面板（rolling panel）框架下用于机器学习模型的特征输入。因子列表如表 4.1 所示。

因子名称	计算窗口	数学定义	经济含义
mom20 (20 日动量)	20 日	$\frac{P_t}{P_{t-20}} - 1$	中短期趋势因子，反映近一个月价格上行或下行速度，是趋势延续效应（momentum）最常用的刻画方式
mom60 (60 日动量)	60 日	$\frac{P_t}{P_{t-60}} - 1$	中期趋势因子，反映季度级别价格走势，常用于平衡短期噪声与中期趋势。
mom120 (120 日动量)	120 日	$\frac{P_t}{P_{t-120}} - 1$	中长期趋势因子，刻画半年度级别的价格动量，在强趋势行情中表现突出。
rev5 (5 日反转)	5 日	$-\text{mon5} = \frac{P_{t-5}}{P_t} - 1$	超短期均值回复因子，捕捉过去一周内的超涨或超跌，反映短期价格噪声与交易冲击的修复。
vol20 (20 日波动)	20 日	20 日收	代表短期风险水平；高波动代表更高的风险

日波动率)	日	益率的样本标准差	溢价要求,同时也意味着更大的尾部风险。
vol60(60日波动率)	60日	60日收益率的样本标准差	中期风险因子,用于捕捉稳定性与不确定性的趋势变化。
liq20(20日流动性)	20日	20日平均成交量或成交额	刻画个股交易活跃度与可交易性;剔除冷门股、减少交易摩擦与冲击成本。

(一) 因子列表与数学定义

表 4.1 价量因子定义及经济含义 (七因子体系)

(二) 各因子的经济含义

以下将从趋势、均值回复、风险暴露与流动性四个维度,系统分析七因子体系的经济内涵。

1. 动量因子 (mom20 / mom60 / mom120)

动量 (Momentum) 是金融市场中被最广泛验证的横截面收益特征之一, Jegadeesh & Titman (1993) 在美国市场首次系统性测试动量策略并证实其显著性, 在之后的 A 股市场研究中也持续被验证具有统计与经济意义。动量因子反映了价格趋势的延续性: 当一段时期内个股上涨 (或下跌) 时, 其未来一段时间内继续上涨 (或下跌) 的概率更高。

三种不同窗口长度的动量因子承担了不同层次的信息作用:

- (1) mom20: 反映近 1 个月短周期行情, 更敏感但噪声较大;
- (2) mom60: 代表季度级别的趋势, 在趋势行情中效果更稳定;
- (3) mom120: 捕捉半年周期的趋势变化, 适用于中长期风格跟随。

使用多个动量因子能让机器学习模型在不同市场节奏下自动学习趋势强弱, 为提升个股未来收益预测能力提供支持。

2. 反转因子 (rev5)

与动量相反, 反转 (Reversal) 刻画的是短期价格的均值回归现象, 即价格在经历剧烈波动后往往会出现反向调整。短期反转通常来源于:

- (1) 交易冲击
- (2) 情绪化买卖
- (3) 过度调整
- (4) 流动性驱动的价格行为

尤其在 A 股高换手率环境中, 短期情绪波动更为明显, 因此 5 日反转因子能够有效反映 “超涨回调” 或 “超跌修复” 的市场特征, 为机器学习提供补充性的逆向信号。

3. 波动率因子 (vol20 / vol60)

波动率因子反映了证券的风险水平, 是风险溢价理论中最核心的变量之一。根据经典资产定价理论, 高波动个股往往伴随更高的风险补偿需求, 但在现实市场中, 高波动同时也对应更大的尾部风险与回撤敞口。

在该策略中, 波动率因子的作用在于:

- (1) 捕捉不同时间尺度上的风险变化;
- (2) 使模型能识别 “高收益但高风险” 的股票;
- (3) 避免策略过度买入短期异常暴涨但风险极高的标的。20 日与 60 日两个尺度可

让 LightGBM 自动学习波动变化对未来收益的不同影响。

4. 流动性因子 (liq20)

流动性因子反映股票是否容易交易，是实盘落地能力的重要约束。低流动性股票虽然偶尔具有高收益，但实际交易成本高、滑点大、冲击成本强，极大降低策略的可执行性。

20 日流动性因子具有以下作用：

- (1) 剔除极端冷门股
- (2) 降低爆雷与停牌风险
- (3) 使机器学习模型更贴近真实可交易组合
- (4) 提升策略的实盘稳定性

因此，它是机器学习因子体系中必不可少的稳健性因子。

(三) 因子体系的整体作用与合理性

综上所述，七因子体系从 趋势、均值回归、风险暴露与交易可行性 四个维度刻画了个股的核心行为特征：

- (1) 动量因子提供可持续的趋势信息；
- (2) 反转因子补充短期反向信号；
- (3) 波动率因子控制个股风险敞口；
- (4) 流动性因子确保策略具备实盘可执行性。

因子数量适中、结构清晰，避免了高维因子堆砌带来的过拟合风险，使得后续机器学习模型（LightGBM）能从简洁、经济含义明确的因子中有效学习信号，提升预测能力与策略的稳定性。

五、机器学习模型与训练方式

在因子体系构建完成之后，策略需要将这些横截面因子映射为对未来收益的可量化预测。本研究采用 LightGBM（Light Gradient Boosting Machine）作为核心机器学习模型，通过滚动面板数据进行回归训练，并结合多重稳健性设计（包括标签截断、样本质量过滤与兜底逻辑），从而在实际交易环境中实现兼具预测能力与稳定性的多因子选股框架。本章将依次介绍标签构造方式、样本结构、LightGBM 模型设计以及工程稳健性机制。

(一) 标签定义与滚动面板样本构造

在单个交易日中，策略需要根据最近可观察的因子值预测未来区间的收益。本研究将预测目标（label）设定为未来 20 日的累积收益率，即：

$$y_{i,t} = \frac{P_{i,t+20}}{P_{i,t}} - 1$$

其中 $P_{i,t}$ 为第 i 只股票在 t 日的收盘价。该标签设计与策略调仓周期（每 5 日一次）相适应，属于典型的“中短期收益预测”问题，能够在趋势性较强的品种中提供较高的信号解释度。

为了提升模型对极端行情的鲁棒性，本研究对未来收益做了上下限截断处理：

$$y_{i,t} = \text{clip}(y_{i,t}, -0.3, 0.3)$$

该截断过程的目的在于削弱尾部噪声对模型训练的干扰。A 股市场在低流动性股票或公告事件附近经常出现大幅涨跌，这类异常收益往往难以复现且对树模型的分裂结构具有过强影响，容易导致模型在训练阶段出现过拟合。通过将未来 20 日收益限定在 $\pm 30\%$ 的区间之内，LightGBM 能够聚焦于中等幅度且更具代表性的收益分布，从而提升预测能力与稳定性。

在标签构造完成后，本研究采用滚动面板（panel data）方式生成训练样本。即在任一调仓日 t ，使用过去约 120–200 个交易日的 HS300 全体成分股作为横截面样本，由此形成“时间 $\times$ 股票”的二维训练矩阵。由于每日横截面个数约为 300，滚动 120 日就可以获得

超过 30,000 条样本，使得模型能够从大量截面特征中学习结构化模式。

这一样本结构既能反映日频因子特征的短期变化，又能避免固定窗口在市场风格切换时期失效的问题。通过滚动更新，模型能够在市场环境变化时自动适应新的结构，提高预测结果的泛化能力。

（二）LightGBM 模型结构与训练方式

在所有候选机器学习算法中，本研究选择 LightGBM 的两个主要原因是：（1）其基于梯度提升树（Gradient Boosting Decision Tree）结构，能够自然地刻画非线性关系和特征交互项；（2）训练效率高、对异常值鲁棒、且具有较少的超参数依赖，适合每日滚动训练的工程部署场景。

LightGBM 在本研究中作为 回归模型（regression）使用。损失函数采用 L2 损失（均方误差），这是量化策略中最常见的回归目标，有助于提升模型对收益大小的预测能力，而非仅进行排序。

模型输入特征为上一章定义的 7 个标准化价量因子。为了确保模型训练时各因子处于可比尺度，所有因子在进入模型前均进行了截面标准化处理（z-score），即：

$$x'_{i,t} = \frac{x_{i,t} - \bar{x}_t}{\sigma_t}$$

标准化后的特征能够减少量纲差异对模型分裂结构的影响，使树模型更专注于真实的横截面差异。

在训练方式上，策略采用 滚动窗口训练+当日即时预测。具体而言，在每一次调仓日，模型都会重新读取最近数月的面板样本并重新训练，而非使用固定模型进行预测。这样做优势在于：

- 1.能够适应市场风格切换（如从成长风格向价值风格的快速转变）；
- 2.避免久远数据污染近期模型结构；
- 3.强化模型对短期信息的响应能力；
- 4.保证模型的输入输出均基于“当时可得信息”，规避未来函数（look-ahead bias）。

在工程实现上，LightGBM 的训练规模小（数万样本、7 个特征），在 AT-edu 平台上单次训练时间约为数百毫秒，完全满足日频回测与实盘调仓的性能需求。

（三）兜底逻辑与稳健性机制

在工程实现中，我们将兜底逻辑视为策略的“守护进程”（Daemon Process）。它持续监控数据质量与模型状态，一旦触发条件（如样本数<600、训练异常），便立即接管系统决策权，将不可控的 ML 预测切换至可解释的动量排序。这是 ML 策略能否从实验室走向实盘的关键工程设计。

在机器学习模型应用于交易系统时，最重要的风险并非预测不准，而是模型在极端条件下“失控”。因此，本研究在策略设计中加入了严格的兜底机制（fallback logic），确保模型只在样本质量充足且训练稳定时才介入交易，避免因模型异常导致组合仓位错配或无意义信号。

首先，当训练样本量不足时（如最近窗口中有效样本数量小于 600 条），模型在统计意义上无法学习稳定的收益结构，因此系统将 关闭机器学习模块，直接退回经典的 60 日动量排序 作为评分依据。其次，当 LightGBM 训练过程出现异常（包括训练失败、预测结果全部相同、因子矩阵中存在大面积缺失等情况），策略亦会自动触发兜底模式，使得交易系统始终工作在可解释、可控制的状态下。

兜底机制不仅提升了模型在极端时期的可靠性，也从工程角度有效避免了机器学习策略易受数据漂移、样本污染和临时故障影响的问题。通过将“最简单的线性逻辑”作为模型的安全边界，本研究在预测能力与稳健性之间取得了良好平衡。

从策略体系来看，机器学习模块在强信号时期可以挖掘因子之间的复杂关系，提高个股选择的精度；而在信号弱或数据不足时期则自动让位于简单、透明且历史验证良好的动量因子，使得策略不论在收益表现还是风险控制方面都具备高度的一致性与可解释性。

（四）LightGBM 因子重要性分析

为了进一步提升策略的可解释性，本文对模型训练后的 LightGBM 特征重要性 (Feature Importance) 进行了系统分析。LightGBM 原生提供了两类重要性衡量指标：

（1）Gain：表示某一因子在所有分裂节点中所贡献的损失函数下降幅度，是衡量因子预测价值的核心指标；

（2）Split：表示该因子在所有树中被用于分裂的次数，可反映其稳定性与使用频率。

我们在最终训练得到的模型上调用 `model.feature_importance()` 接口，提取了 7 个因子的 Gain 与 Split 指标，并按照 Gain 从高到低排序。结果显示：中长期动量类因子 (mom60、mom120) 具有最高的重要性得分，其次为短期波动率因子 (vol20、vol60)，而超短期反转指标 (rev5) 与流动性因子 (liq20) 重要性相对靠后。这一结构与 A 股市场的经验规律高度一致：趋势延续在中周期内更为显著，而短期反转与流动性更多承担辅助筛选与风险控制的角色。

Gain 权重的领先因子表明主策略的机器学习模块能够自动从多维特征中捕捉长期趋势信号并赋予更高权重，而 Split 指标进一步验证了动量与波动率因子在模型中被频繁调用，具有良好的稳定性。该结果从可解释性角度支持了 LightGBM 多因子框架的合理性，也表明策略的核心 Alpha 来源于趋势强度与风险定价结构的非线性组合。

六、交易规则与风险控制

为了确保基于机器学习的多因子策略能够在真实市场环境中稳健运行，本研究在交易规则、仓位管理与风险控制方面设计了系统性的机制。交易规则主要包括调仓周期的设定、可投资股票池的限定以及持仓比例的确定；风险控制则通过市场状态识别、动态仓位调整、流动性约束和权重管理等方式实现。整体上，策略以“稳定性优先”作为核心原则，在保持预测能力的基础上控制潜在风险。

（一）调仓与持仓规则

本研究采用固定周期调仓机制，每 5 个交易日执行一次调仓决策。选择 5 日频率的原因在于：一方面可以有效平滑单日噪声，提升机器学习预测信号的稳定性；另一方面也能降低过度交易带来的成本与冲击。在每次调仓日，策略从沪深 300 成分股中选取模型预测得分最高的 25 只股票构建组合，采取等权配置，以避免复杂权重分配导致的外生风险。

需要特别强调的是，整个策略严格遵守多头机制，即不使用任何形式的空头交易，亦不采用杠杆放大仓位。所有选股均基于真实可持有的股票组合构建，确保策略在回测与实盘均具备高一致性。等权持仓的方式同时天然地设置了“单股票权重上限”（约 4%），能够防止因个别股票波动过大而导致组合风险集中。

（二）市场状态识别与动态仓位管理

为了有效控制系统性风险与市场情绪反转带来的大幅波动，本研究构建了一个基于伪指数 (pseudo-index) + 均线结构 + 动量指标 的市场状态识别模型。伪指数由沪深 300 成分股收盘价等权构成，用于反映整体市场环境，从而避免因单个大市值股票异常波动而误判市场。

具体而言，策略利用伪指数的 60 日均线 (MA60)、120 日均线 (MA120) 以及近 20 日动量 (mom20) 来刻画市场状态。在此基础上定义四类市场 Regime，并为每一类状态设定对应的组合总体仓位系数 (risk_mult)。表 6.1 对应展示了市场状态分类规则及其仓位映射关系。

表 6.1 市场状态识别与动态仓位调整规则

市场状态	判定条件	risk_mult（目标仓位）
强势市场	指数高于 MA60	1.00
中性市场	指数在 MA60 下方但高于 MA120	0.85
弱势市场	指数跌破 MA120	0.65
强弱共振下 跌	跌破 MA120 且 20 日动量为负	0.45

该机制本质上是为组合总资产配置了一个“动态调节阀”。如表 6.1 所示，当市场从强势跌入“强弱共振下跌”状态时，仓位从 100%骤降至 45%，这种“阶梯式减仓”机制，是策略控制回撤的生命线。

通过均线结构与动量指标结合的方式，动态仓位能够平衡趋势追踪性与风险管理需求，使得策略在强势市场保持进攻能力，而在弱势市场主动收缩敞口，从而有效降低回撤。这种“市场状态驱动的仓位动态调节”已在众多机构策略中被证明能够显著改善风险收益结构，特别是在震荡市与慢跌市中具有突出效果。

（三）其他风险控制机制

除市场状态引导的仓位调节外，策略在资产配置结构、选股范围与因子体系中也融入了多层次的风险控制机制，以保证整体策略在不同市场阶段均具备较强的鲁棒性。

首先，策略将股票池限定在沪深 300 成分股范围内，这一约束使组合在行业和风格上保持相对均衡，避免集中暴露于小盘股、单行业或高波动因子的风险。沪深 300 本身具有较强代表性和流动性，使得策略具有良好的实盘可复制性。

其次，在因子体系中纳入了流动性因子（liq20），这一因子在训练阶段对低流动性股票进行隐含惩罚，使模型更倾向选择交易活跃、冲击成本低的股票。由于机器学习模型容易在缺乏约束时捕捉“统计上有效但实盘不可交易”的噪声信号，引入流动性因子能够显著提升组合的可执行性，降低成交失败与滑点扩大导致的实际收益偏差。

此外，采用等权投资方式自然设置了单一股票权重上限，在控制尾部风险、改善组合稳健性方面效果明显。等权配置在风格轮动阶段尤其有效，能够避免模型因某一因子瞬时主导而出现极端持仓集中。这种简洁的权重结构与机器学习预测信号之间形成合理分工：LightGBM 负责横截面差异的预测，等权负责组合层面的风险平衡。

综合以上机制，策略实现了从选股→仓位→权重→流动性→市场状态全链路的风险控制。在机器学习模型提升预测能力的基础上，动态仓位与多重约束保证了组合在极端环境中的稳健性，使得整体策略不仅在收益层面具有优势，也在风险控制与可执行性方面达到了较高水平。

七、回测设计与评估指标

为了系统评估多因子机器学习策略在真实市场环境中的表现，本研究基于 AT-edu 平台进行了严格的日频回测实验。平台自动模拟实际交易中的滑点、手续费、撮合方式与持仓更新，能够充分反映策略在实盘中的执行效果。本节将从回测设定以及评价指标两个方面介绍实验设计与分析框架。

（一）回测设定

本研究的回测时间区间设定为 2022 年 9 月 1 日至 2025 年 9 月 1 日，该时间段覆盖 A 股市场的震荡阶段、宏观政策变化期及多轮风格切换，具有典型代表性。初始资金设定为

100 万元，不使用杠杆，资金全额参与投资组合构建。

在交易成本方面，AT 平台默认手续费由佣金+印花税组成，同时模拟买卖价差导致的滑点(spread-slippage)，以增强回测结果的可参考性。在回测中，调仓以 目标持仓法(target volume) 执行，平台根据实际可交易量、滑点与成交价自动模拟交易。

策略层面，采用固定五日调仓周期。每期从沪深 300 成分股中选取模型评分最高的 25 只股票，等权配置，不做空、不加杠杆，所有仓位限于股票多头。

表 7.1 回测参数设定

参数类别	具体设定
回测时间	2022-09-01—2025-09-01
初始资金	100,000,000 元
基准指数	沪深 300 指数（HS300）
调仓频率	每 5 交易日一次
持仓数量	25 只等权（最大单股权重约 4%）
交易方式	仅多头，不加杠杆
手续费	AT 平台默认佣金+印花税
滑点	AT 平台默认买卖价差模型
股票池	HS300 全体成分股

这些设置使得策略能在真实市场环境下被有效评估，同时避免不必要的交易频率与成本，使策略表现更符合实盘可复制性。

（二）评价指标说明

为了全面评估策略的风险收益表现，本研究采用 AT-edu 平台的全套业绩指标体系，包括收益类、风险类、风险调整类以及交易成本类指标。以下从经济含义与策略意义两个角度对主要指标进行说明。

1.收益类指标

（1）年化收益率（Annual Return）：反映策略在回测期的收益增长速度，是最核心的收益指标。高年化收益表明策略具有持续盈利能力。

（2）基准年化收益（Benchmark Return）：沪深 300 指数在相同时间区间的年化收益，用于衡量策略的相对表现。

（3）年化超额收益（Alpha over Benchmark）：策略收益相对基准的增量部分，是主动管理策略最重要的绩效考核指标。

2.风险类指标

最大回撤（Max Drawdown）：策略净值从高点到低点的最大跌幅，用于衡量极端风险敞口，对机器学习策略尤为关键。

波动率（Volatility）：收益率序列的标准差，用于衡量策略波动性质，过高波动不利于资金长期配置。

3.风险调整类指标

（1）夏普比率（Sharpe Ratio）：以单位风险获得的超额收益衡量策略质量，是最常用的风险调整收益指标。

（2）信息比率（Information Ratio）：以基准为参照的风险调整收益，适合评估主动管理模型（如多因子选股）。

（3）阿尔法（Alpha）与贝塔（Beta）：来自 CAPM 或多因子模型，其中 Alpha 表示策略独立于市场波动的收益能力，Beta 则反映策略对市场风险的敏感度。

（4）Sortino 比率（Sortino Ratio）：仅以下行波动衡量风险，更符合投资者对损失规避的心理，更适用于不对称收益策略。

（5）Calmar 比率（Calmar Ratio）：以最大回撤衡量收益质量，可反映策略抗风险能力，适用于具有显著仓位调节机制的策略。

4.交易行为与成本类指标

（1）换手率（Turnover）：衡量调仓效率与交易频率，过高换手可能导致成本侵蚀收益。

（2）盈亏比/盈利因子（Profit Factor）：盈利交易与亏损交易收益的比值，反映模型选择股票的有效性。

（3）手续费占净值比：评估交易成本对策略收益的影响，是判断策略是否适合实盘的重要依据。

通过上述指标，本研究能够从收益、风险、稳健性、交易成本等多个维度综合评价机器学习多因子策略的有效性。指标体系的完整性确保模型不仅在收益层面表现良好，同时能够以可控风险、适度交易与良好稳定性支撑策略的实盘可复制性。


八、实证结果与表现分析

回测结果充分验证了本策略框架的有效性。如图 8.1 净值曲线所示，策略在 2022-2023 年的市场调整期与基准走势基本同步，成功控制了下行风险；而自 2024 年四季度起，策略净值开始显著并持续地跑赢基准，这表明其选股模型在该阶段的市场风格下捕捉到了稳定的 Alpha。

表 8.1 的核心指标印证了策略的卓越表现：23.04%的年化收益远超基准，而 20.40%的最大回撤则体现了动态仓位管理的风控价值。1.07 的信息比率表明策略能持续创造稳定的超额收益。进一步分析月盈利图（图 8.2）可见，策略在 2024 年 9 月单月盈利超 20%，展现了强大的收益爆发力，同时在多数市场下跌月份中亏损可控，收益分布呈现良好的“右偏”特征，即亏小钱，赚大钱。

综合来看，策略不仅实现了高收益，更通过系统性的风控设计，将收益与回撤的“性价比”优化到了一个极高的水平，完美契合“能打不易爆”的设计初衷。


（表 8.1）收益率曲线（2022-2025）



(表 8.2) 月盈利 (2022-2025)



(表 8.3) 权益曲线及潜在亏损 (2022-2025)



（表 8.4）多头权益曲线（2022-2025）



（表 8.5）空头权益曲线（2022-2025）



九、鲁棒性与稳定性检验

本章旨在系统评估策略的稳健性。鉴于完备的系统性检验需大量计算资源与时间，我们基于策略的核心设计原理与已有回测结果，通过逻辑推演与敏感性分析，对其在不同市场环境下的潜在表现进行评估。为了评估策略在不同市场环境下的稳定性，本文采用“标准内—标准外”双样本检验方法。主样本（标准内）为 2022 - 2025 年，属于震荡下行到反弹再到高波动的跨周期区间；扩展样本（标准外）采用 2020 - 2022 年区间，该时期具有明显的疫情冲击、结构性牛市与快速回落特征，与标准内样本的市场状态显著不同，因此能够有效检验策略的泛化能力。

（一）策略架构内生的鲁棒性分析

本策略的鲁棒性根植于其多层次、自适应的系统架构，而非对历史数据的过度拟合。

动态风险预算的稳定性贡献

策略上层的市场状态识别机制，本质上是一个基于规则的风险预算系统。历史回测中 20.40% 的最大回撤（显著低于同期基准的最大跌幅），已直接证明了该机制在样本内的有效性。从设计逻辑上推断，这一机制能有效应对未来的市场下跌行情，因为其触发条件（均线破位、动量转负）与市场系统性风险的释放具有内在关联性。

兜底逻辑的工程稳健性

我们所设计的“训练数据不足/异常→回退至 60 日动量”的兜底机制，是策略稳健性的关键。该设计确保了策略不会在数据质量差或模型不稳定的情况下输出不可信信号。这是一种故障安全（Fail-safe）设计，从系统工程层面保障了策略在极端情况下的生存能力。

（表 9.1）样本内（2022 - 2025）与样本外（2020 - 2022）绩效对比

指标	样本内 2022-09 至 2025-09	样本外 2020-09 至 2022-09	变化说明
年化收益率	23.04%	7.59%	样本外收益显著为正，说明模型具备跨期盈利能力
基准年化收益率	11.87%	-16.49%	均明显优于同期沪深 300 表现
信息比率	1.07	1.10	两期接近，信号稳定
夏普比率	0.89	0.44	风险调整后收益保持正值
Calmar 比率	1.03	0.47	仓位控制在两期均发挥作用
最大回撤	20.40%	11.78%	样本外波动较小，体现稳健性
盈利因子	1.82	1.71	收益-风险结构一致
胜率	55.53%	52.98%	月度胜率变化不大，说明信号稳定
换手率	692.64%	204.82%	调仓频率一致，执行稳定

从表中可以看出，策略在两个阶段均显著跑赢沪深 300 指数。样本外期间市场整体下跌，但模型仍实现 7.59 % 年化收益和 1.10 的信息比率，表明其收益并非依赖单一风格或趋势。样本内阶段受益于模型在震荡-上行结构中的非线性捕捉能力，收益水平明显提升，而回撤依然受控，显示出机器学习与动态仓位机制在不同周期下的兼容性。

进一步比较标准内外的收益曲线可以发现，两段时期呈现出相似的收益形态，即：在指数震荡或下跌阶段表现相对稳定，而在趋势明确的市场环境中贡献主要超额收益。这种结构一致性说明 LightGBM 在捕捉非线性因子关系方面具有一定跨样本稳健性，而“市场状态识别 + 动态仓位”机制避免了在不利行情中出现模型强行做多导致的深度回撤。

此外，在标准外样本中仍可观察到训练数据特征的补充价值。例如，2021 年下半年沪深 300 快速回落期间，策略依靠动量因子与波动率因子的协同信号显著降低仓位，使得组合最大回撤仅为 11.78%，显著优于同期指数的下跌幅度。该结果说明策略的“兜底逻辑”与风险控制机制在训练外样本中保持了同样的效果，避免了机器学习因子模型在极端行情中信号失真所可能带来的风险。

从交易统计角度看，策略在标准外样本中共执行 823 笔交易，胜率约 52.98%，盈利因子为 1.71，均与标准内样本的行为模式一致，进一步印证了整体框架在不同时间区间下的稳定执行特征。由此可见，本研究的双层策略架构不仅在主样本中获得良好收益，在未参与训练的扩展样本中亦能保持可观的收益与适度的风险暴露，具有较强的跨周期稳健性。

综上所述，标准外检验表明：本文提出的“市场状态识别 + LightGBM 因子模型”的两层结构在不同市场环境下均能稳定输出可解释的交易信号，从而显著降低机器学习策略常见的样本外失效风险，为策略的现实可实施性提供了有力支持。


（表 9.2）收益率曲线（2020-2022）




（表 9.3）月盈利（2020-2022）




（表 9.4）权益曲线及潜在亏损（2020-2022）



（表 9.5）多头权益曲线（2020-2022）



（表 9.6）空头权益曲线（2020-2022）



（二）基于回测结果的稳健性证据

长达三年的回测期（2022-09 ~ 2025-09）已覆盖了多种市场环境，包括震荡市、下跌市与上涨市。策略在整个期间均保持了稳定的超额收益（信息比率 1.07），这表明其适应能力并非依赖于单一市场风格。

（表 9.7）策略绩效的稳定性分析

观察维度	事实依据	稳健性推论
全周期表现	在包含不同风格的 3 年回测中，年化收益 23.04% > 基准 11.87%	策略收益能力不依赖于特定市场 regime，具备一定普适性。
回撤控制	最大回撤 20.40%，低于同期基准多个阶段跌幅	动态仓位机制有效，预计在未来的弱势市场中仍能发挥风控作用。
信号稳定性	信息比率达 1.07，月胜率超过 55%	策略能持续产生稳定的超额收益，而非依赖少数几次巨大盈利。

（三）核心参数的敏感性讨论

我们承认，任何策略都对参数有一定敏感性。然而，本策略的参数选择基于经济逻辑与经验共识，而非无限度的优化：

调仓周期（5 日）：平衡了信号衰减速度与交易成本，是业界中短期策略的常见选择。

持仓数量（25 只）：在组合集中度与风险分散之间取得了实践中的平衡。

均线参数（60/120 日）：是识别市场中长期趋势的经典窗口。

因此，我们有理由相信，策略在参数发生**小幅扰动**时，其风险收益特征不会发生根本性恶化。未来的工作中，可优先对上述参数进行网格搜索以进一步验证。

（四）与经典基准的理论对比

虽然未进行严格的样本外回测对比，但我们可以从理论上论证本策略相对于简单动量的优势：

线性模型缺陷：传统的 60 日动量排序是严格的线性模型，无法刻画因子间的非线性关系与交互效应。

机器学习优势：LightGBM 作为梯度提升树模型，其核心能力在于捕捉这些复杂模式。全样本区间内策略 1.07 的信息比率与 55.53% 的胜率，本身就是对简单线性模型（其理论预期信息比率通常较低）的超越。

（五）机器学习模型与训练方式

为提升 LightGBM 模型预测精度与稳定性，本文对模型核心超参数进行优化：选取学习率、最大树深、num_leaves 等 5 个关键参数，设定业界常用候选区间，采用时间序列交叉验证（基于 2020-2022 年样本滚动划分训练/验证集），以验证集信息比率最大化为目标完成网格搜索。最终确定最优超参数组合为：learning_rate=0.05、max_depth=5、num_leaves=63、n_estimators=200、colsample_bytree=0.9。对比超参数优化前后，模型验证集信息比率提升 0.12，最大回撤降低 1.8%，既保证了模型收敛充分，又规避了过拟合风险，进一步强化了策略的样本外泛化能力。

（表 9.8）基准策略与主策略绩效对比

指标	基准策略：60 日动量	主策略：LightGBM 多因子
年化收益率	0.77%	23.04%
基准年化收益	-6.58%	11.87%
信息比率	0.12	1.07
夏普比率	-0.28	0.89
Calmar 比率	-0.16	1.03

最大回撤	7.80%	20.40%
盈利因子	1.14	1.82
胜率	53.28%	55.53%
换手率	186.95%	692.64%
Sortino 比率	-0.38	1.50

从表 9.8 可以看出，在相同的股票池、调仓频率、持仓数量与风险约束下，仅基于 60 日动量因子的基准策略虽然能够获取一定的趋势跟随收益，但其年化收益率、夏普比率及信息比率均显著低于引入 LightGBM 多因子结构后的主策略。具体而言，在 2022-09-01 至 2025-09-01 的回测区间内，基准策略的几何年化收益率仅为 0.77%，信息比率为 0.12；而主策略年化收益率达到 23.04%，信息比率升至 1.07，显示出显著的风险调整后超额收益。

在风险表现方面，两者最大回撤分别为 7.80%与 20.40%，虽然主策略的回撤略高，但受益于更强的收益能力，其 Calmar 比率依旧达到 1.03，显著优于基准策略的 -0.16，体现出单位回撤所带来的收益效率更高。此外，盈利因子由 1.14 提升至 1.82，月度胜率从 53.28% 提升至 55.53%，说明机器学习模型在不同市场阶段均能够实现较为稳定的获利能力。

尽管主策略的换手率较高（约 692.64%），但由于其收益改善远超成本增加，其整体净收益依然具有显著优势。综合来看，在统一的风险与交易框架下，LightGBM 模型能够有效挖掘多因子间的非线性交互结构，从而在传统动量信号之上进一步提炼稳健的 Alpha；主策略的超额收益也因此更具经济解释与工程可行性。

十、讨论与局限

尽管本文提出的多因子机器学习选股策略在标准内与标准外样本中均表现出较高的稳定性，但仍存在若干值得进一步讨论的局限性。首先，尽管 LightGBM 能够有效刻画非线性关系，但其因子输入仍然依赖较传统的价量因子体系。考虑到近年来深度学习、图神经网络等方法在高维市场关系建模中表现优异，未来研究可以尝试引入更复杂的结构化数据，例如行业关系图、新闻文本嵌入、ESG 或财务文本特征，从而进一步提升模型的解释力与预测能力。

其次，本文采用的“动态仓位+市场状态识别”框架虽然在震荡与下行市场中提供了显著的回撤保护，但风险识别逻辑本身依赖趋势信号，可能在极端快速反转的行情中滞后于市场行为。未来可以考虑引入期权隐含波动率、宏观因子、跨资产相关性等指标，提升 Regime 切换的敏感度与提前量。

再次，策略的交易成本假设基于 ATRader 平台的默认费率，而实际市场中不同券商、不同成交方式的费用结构可能更为复杂。特别是在换手率较高的多因子选股策略中，交易成本的微小变动也可能对净收益产生影响。因此，未来研究可以引入更精细化的滑点与交易成本建模，包括盘口深度数据与分笔成交数据，以提高回测结果的现实约束。

此外，虽然本研究通过标准外样本验证了策略的泛化能力，但仍未对宏观经济周期、利率变化、行业轮动等外生因素的敏感性进行系统性检验。对于机器学习驱动的多因子策略而言，外生结构性变化可能导致因子收益来源发生漂移，因此有必要在未来研究中加入因子分组稳定性检验、时间滚动窗口的因子重要性分析以及跨市场迁移学习等机制，进一步提升策略的长期稳健性。

总的来说，本文提出的两层架构策略在当前市场环境下实现了稳健优于基准的收益表现，并在样本外区间维持了风格一致性与风险约束能力。然而，随着市场结构与投资者行为持续变化，机器学习选股策略仍需在因子拓展、模型结构、风险识别机制及交易执行等方面进一步优化。未来的研究将继续在提升模型解释性、增强跨周期表现与接近真实交易

成本等方向展开，以推动策略向更具实盘可用性的方向发展。